Machine Learning HW7

MLTAs
ntumlta2019@gmail.com

Outline

- Task Description - Unsupervised Learning
  - Task A: PCA of colored faces
  - Task B: Image clustering
- Kaggle
- Requirements & Regulation
- Grading Policy
- FAQ

Outline

- Task Description - Unsupervised Learning
  - Task A: PCA of colored faces
  - Task B: Image clustering
- Kaggle
- Requirements & Regulation
- Grading Policy
- FAQ

PCA of colored faces - requirements 2/3

1. 只能用 scikit-image 讀寫圖片
2. 只能用 numpy.linalg.svd 或 np.linalg.eig 實做PCA
3. 將各張圖片分解成Eigenvector (Eigenface)

$$x - \bar{x} \approx c_1 u^1 + c_2 u^2 + \cdots + c_K u^K = \hat{x}$$

Reconstruction error: $\| (x - \bar{x}) - \hat{x} \|_2$

Find $\{u^1, \ldots, u^K\}$ minimizing the error

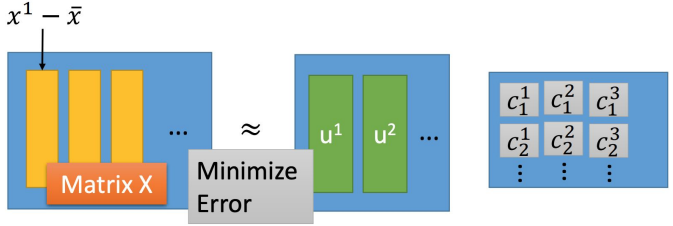

4. 每一個Eigenface 都對應到不同的Eigenvalue
5. 將Eigenface由大到小排列，選出前五大的Eigenface 重建出圖片

PCA of colored faces - reminder 3/3

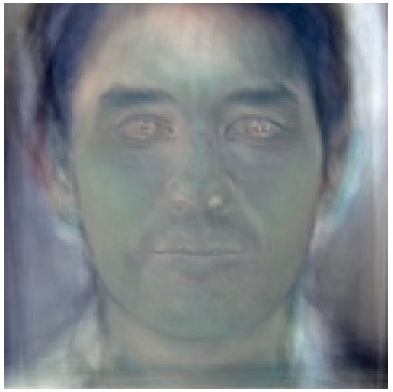

- 請記得先減去平均再計算Eigenfaces, Eigenvalues
- Eigenfaces 是奇怪的顏色是正常的，如右上圖(第十個Eigenface)
- 因為 Eigenfaces 會有負值，因此在畫圖時，請用以下方式轉換：
  - `M -= np.min(M)`
  - `M /= np.max(M)`
  - `M = (M * 255).astype(np.uint8)`
- 程式只會執行最多七分鐘。
- 只能 import numpy 和 skimage (and other python standard library)
- 程式的結果是有標準答案的(可容許每個值相差 ±3 以內)，可以事先和同學比看看
- 可以參考老師的投影片：Link

Outline

- Task Description - Unsupervised Learning
  - Task A: PCA of colored faces
  - Task B: Image clustering
- Kaggle
- Requirements & Regulation
- Grading Policy
- FAQ

Image clustering - outline 1/7

- 目標:分辨給定的兩張 images 是否來自同一個 dataset
  - 所有的 image 都來自兩個不同的class (CelebA & cifar10)
  - 除了 image 都是32*32*3的圖片，沒有任何 label
  - 只能用我們給的 data，不能使用額外的 dataset，也不能使用額外資料 train 的 model

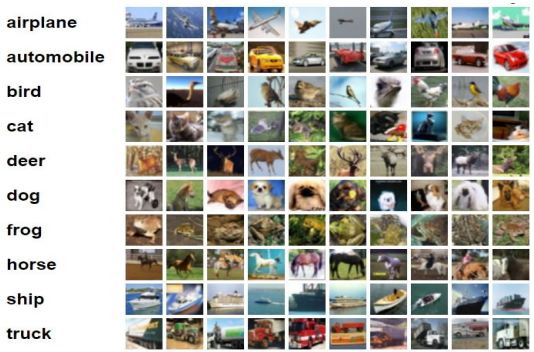

Image clustering - data 2/7

- images.zip
  - Usage: unzip images.zip
  - 會得到一個叫images/ 的資料夾，裡面總共有40000 張 RGB圖片，大小都是32*32*3
- visualization.npy
  - 在 kaggle deadline 之後會公布一個小型的dataset
  - 包含 5000 張 images，前 2500 張 images 跟後 2500 張 images 是分別從兩個 dataset 得到的
  - 請用訓練的模型在report對這個 dataset 做 visualization

Image clustering - data 3/7

- test_case.csv
  - 每一行都有 id, image1_name, image2_name，總共有 1,000,000 筆測資
  - id: test case index
  - image1_name: 對應到 images/ 裡的圖片的名稱
  - image2_name: 對應到 images/ 裡的圖片的名稱
- sample_submission.csv
  - 第一行是 “id, label” (5/11 update)
  - 之後每一行都會有 test case ID，以及對這個 test case 的 prediction
  - 如果 test case 的兩張 image 預測後是來自同一 dataset，Ans 的地方就是 1，反之是 0

Image clustering - methods 4/7

- 如果直接在原本的 image 上做 cluster，結果會很差 (有很多冗餘資訊)

  => 需要更好的方式來表示原本的image

- 為了找出這個更好的方式，可以先將原始 image 做 dimension reduction，用比較少的維度來描述一張 image

  e.g. autoencoder, PCA, SVD, t-SNE

Image clustering - requirements 5/7

1. 請實作用 **autoencoder** 將40000張圖片降維
2. 再利用降維過的latent code做分類
3. 預測1000000筆測資是否來自相同的dataset

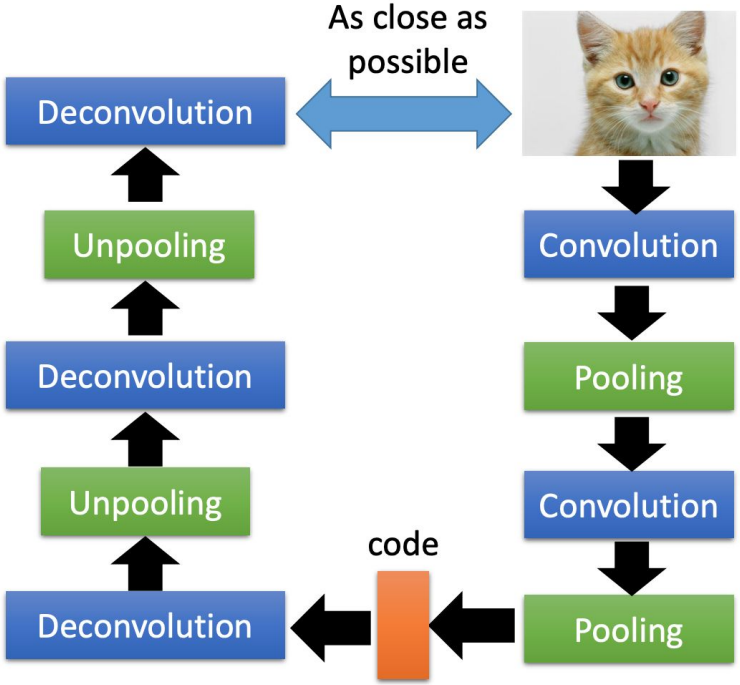

註: 同學實作的方法需含有autoencoder, 但還是可以將其他的降維方法一起搭配使用 (5/14 更新)

Image clustering - methods (cont.) 6/7

- 接著對降維過後過後的數據做 cluster
  - cluster：可以試試 K-means

- 或者你可以衡量兩個降維過後的 images，他們之間的相似度 (similarity)。如果相似度大於一個設定好的 threshold，就把這兩個 images 當成同一類別
  - 算 similarity 的方法：euclidean distance, cosine similarity……

Image clustering - methods (cont.) 7/7

- 其他可能有幫助的事：
  - 必須找個方法來衡量方法的好壞，一個直覺的方法是利用降維過後的feature 去 reconstruct 成原本的 image。如果 reconstruct 的結果越接近原本的image，可以一定程度的代表你抽出來的feature 越好
  - 對原始 image 做 data augmentation
  - try different number of cluster
  - 看看老師 unsupervised learning 上課內容

Outline

- Task Description - Unsupervised Learning
  - Task A: PCA of colored faces
  - Task B: Image clustering
- Kaggle
- Requirements & Regulation
- Grading Policy
- FAQ

Kaggle - Info 1/2

- Kaggle 連結 : https://www.kaggle.com/c/ml2019spring-hw7
- 個人進行，不需組隊
- 隊名:
  - 修課學生：學號_任意名稱（ex: b08901777_活大好好吃）
  - 旁聽：旁聽__任意名稱
- 每天上傳上限 5 次
- Leaderboard上所顯示為public score，在Kaggle Deadline前可以選擇2份submission作為private score的評分依據。
- test set的資料將被分為兩份，一半為public，另一半為private。
- 最後的計分排名將以2筆自行選擇的結果，測試在private set上的準確率。
- ★ kaggle名稱錯誤者的分數將x0.7。

Kaggle - format 2/2

- 預測 1000000 筆 testing data 是否來自相同的dataset，將預測結果上傳至kaggle
  - Upload format : csv file
  - 第一行必須是 id,label
  - 第二行開始，每行分別為id值及預測結果 (binary)，以逗號隔開

  - 預測後是來自同一 dataset，label 的地方就是 1，反之是 0
  - Evaluation: Accuracy

- 範例格式如右

sample_submission.csv

```
id,label
0,0
1,0
2,0
3,0
4,0
5,0
6,0
7,0
8,0
9,0
10,0
11,0
12,0
13,0
14,0
15,0
16,0
17,0
18,0
19,0
20,0
```

Outline

- Task Description - Unsupervised Learning
  - Task A: PCA of colored faces
  - Task B: Image clustering
- Kaggle
- Requirements & Regulation
- Grading Policy
- FAQ

Requirements

- Task A: PCA of colored faces
  - 不用上傳kaggle
  - 用PCA實作出 eigenface, 及eigenface reconstruct 的結果
  - 回答report 問題

- Task B: Image clustering
  - 將預測結果上傳kaggle
  - 用autoencoder 實作降維
  - 回答report問題
  - 不能使用額外的data訓練，也不能使用pre-trained model
  - 不能 call 其他線上 API

Regulation 1/3

- **Python Only**，請使用 Python 3.6
- Python standard library are available
- **PCA of colored faces:**
  - Numpy >= 1.14
  - scikit-image == 0.15.0
- **Image clustering:**
  - Numpy >= 1.14, Pandas >= 0.20
  - Keras == 2.2.4, Tensorflow >= 1.12.0 , pytorch == 1.0.1
  - Scipy == 1.2.1
  - scikit-image == 0.15.0
  - scikit-learn == 0.20.3
  - Pillow == 6.0.0
- **若需要其它套件，請及早來信詢問。**若 import 有發生錯誤，分數將x0.7

Regulation - GitHub 2/3

- 你的 github 上 ML2019SPRING/hw7/ 中請包含：
  - report.pdf
  - pca.sh（for PCA of colored face 那題）（限時7分鐘）
  - cluster.sh (for image clustering 那題，限制用autoencoder實作)（限時10分鐘）
  - your python files
  - your model files (can be loaded by your python file)

- **請不要上傳 dataset，請不要上傳 dataset，請不要上傳 dataset。**
- 如果你的 model 超過 github 的最大容量，可以考慮把 model 放在其他地方 (http://slides.com/sunprinces/deck-16#/2%EF%BC%89)。
- model 可以是多個檔案，例如 keras model。如果你的 code 需要極長的執行時間，可以把 image cluster 後的結果寫進一個 file，並在執行時讀取它。

Regulation - Script Usage 3/3

- 以下的路徑，助教在跑的時候會另外指定，請保留可更改的彈性，不要寫死

  a. **PCA of colored faces:**

  bash pca.sh <images path> <input image> <reconstruct image>

  e.g. bash pca.sh Aberdeen/ 87.jpg 87_reconstruct.jpg

  b. **Image clustering:**

  bash cluster.sh <images path> <test_case.csv path> <prediction file path>

  e.g. bash cluster.sh images/ test_case.csv ans.csv

- Script 所使用之模型，如 hdf5, pt, pickle 檔等，可以於程式內寫死路徑，助教會 cd 進 hw7 資料夾執行 reproduce 程序。

Outline

- Task Description - Unsupervised Learning
  - Task A: PCA of colored faces
  - Task B: Image clustering
- Kaggle
- Requirements & Regulation
- Grading Policy
- FAQ

Grading Policy - Deadline 1/7

- Early Simple Deadline: 2019/05/16 11:59:59 (GMT+8)
- Kaggle Deadline: 2019/05/23 11:59:59 (GMT+8)
- Github Deadline: 2019/05/24 23:59:59 (GMT+8)

助教會在deadline一到就clone所有程式，並且不再重新clone任何檔案

若遲交請填寫遲交表單: Link

Grading Policy - Evaluation (5% + Bonus 1%) 2/7

- (1%) 超過public leaderboard的simple baseline分數
- (1%) 超過public leaderboard的strong baseline分數
- (1%) 超過private leaderboard的simple baseline分數
- (1%) 超過private leaderboard的strong baseline分數
- (1%) 2019/05/16 11:59:59 (GMT+8)前超過public simple baseline

- (BONUS 1%) private leaderboard 排名前五名且於助教時間上台分享的同學

Grading Policy - Report 3/7

1. **PCA of color faces:**
   a. (0.5%) 請畫出所有臉的平均。
   b. (0.5 %) 請畫出前五個 Eigenfaces，也就是對應到前五大 Eigenvalues 的 Eigenvectors。
   c. (0.5%) 請從數據集中挑出任意五張圖片，並用前五大Eigenfaces 進行 reconstruction，並畫出結果。
   d. (0.5%) 請寫出前五大 Eigenfaces 各自所佔的比重，也就是 $\frac{s_i}{\sum s_j}$ 請用百分比表示並四捨五入到小數點後一位。

Grading Policy - Report 4/7

2. Image clustering:

a. (1%) 請實作兩種不同的方法，並比較其結果(reconstruction loss, accuracy)。(不同的降維方法或不同的cluster 方法都可以算是不同的方法)

b. (1%) 預測 visualization.npy 中的 label，在二維平面上視覺化 label 的分佈。(用 PCA, t-SNE 等工具把你抽出來的feature 投影到二維，或簡單的取feature 的前兩維)

其中visualization.npy 中前 2500 個 images 來自 dataset A，後 2500 個 images 來自 dataset B，比較和自己預測的label 之間有何不同。

★ visualization.npy 會在kaggle請用train好的模型去預測

Grading Policy - Report 5/7

2. Image clustering:

c. (1%) 請介紹你的model架構(encoder, decoder, loss function...), 並選出任意32張圖片, 比較原圖片以及用decoder reconstruct的結果。

★ 請勿使用此範例圖片！！

Grading Policy - Report 6/7

- 限制
  - 檔名必須為 report.pdf !!!
  - 檔名必須為 report.pdf !!!
  - 檔名必須為 report.pdf !!!
  - 請用中文撰寫 report（非中文母語者可用英文）
  - 保留各題標題
  - 請標明系級、學號、姓名，並按照report模板回答問題，切勿隨意更動題號順序
  - 若有和其他修課同學討論，請務必於題號前標明collaborator（含姓名、學號）
- Report模板連結
  - 連結：Link

- 截止日期同 GitHub Deadline: **2019/05/24 23:59:59 (GMT+8)**

Grading Policy - Other Policy 7/7

- **Lateness**
  - Github 遲交一天(不足一天以一天計算) hw7 所得總分將 x0.7
  - 不接受程式 or 報告單獨遲交
  - 不足一天以一天計算，不得遲交超過兩天，有特殊原因請找助教。
  - Github 遲交表單: 遲交請先上傳遲交檔案至自己的github 後再填寫遲交表單，助教群會以表單填寫時間作為繳交時間手動clone 檔案。
- **Script Error**
  - 當 script 格式錯誤，造成助教無法順利執行，請在公告時間內寄信向助教說明，修好之後重新執行所得 kaggle 部分分數將x0.7。
  - 可以更改的部分僅限syntax及io的部分，不得改程式邏輯或是演算法，至於其他部分由助教認定為主。
  - 不接受任何 py 檔的 coding 錯誤更改

FAQ

- 若有其他問題，請寄信至助教信箱，**請勿直接私訊助教**。
- 有問題建議可以在 FB Group 裡面留言發問，可能很多人都有一樣的問題
- 助教信箱 ntumlta2019@gmail.com